

От обращения к действию

Собираем AI-агента, который понимает запрос, проверяет факты и доводит работу до результата.

Что строим · Как работаем · Чем проверяем

○ Клиент пишет
«Нужно заменить смеситель.
Сможете завтра?»


○ Агент уточняет и проверяет
Адрес, услуга, контакт.
Зона, цена, правила.

○ Результат подтверждён
Заявка создана.
Или обращение передано
оператору.

- Цель практики

Один сервис. Законченный путь обращения.

Каждый новый модуль расширяет уже работающий проект.



Ты учишься управлять
качеством работы ИИ.

Финальный результат – воспроизводимый сценарий: от входного сообщения до сохранённого результата, с проверками и объяснением решений.

- Маршрут

Сначала основа. Затем интеллект. После – устойчивость.

Организовать работу

- M0** Процесс с ИИ
Промпт, ревью, тесты, понимание
- M1** API и хранение
Поднять и дополнить каркас
- M2** Вызовы LLM
Извлечение и учёт расходов

Собрать поведение

- M3** Контекст и диалог
Уточнения и исправления
- M4** Классификация
Тип и приоритет обращения
- M5** Знания и проверки
SQL, RAG и доступ к источникам
- M6** Граф и действия
Инструменты и оператор

Проверить систему

- M7** Качество и защита
Ошибки, регрессии, атаки
- M8** Нагрузка и бюджет
Очередь, сбои, повторы, кеш
- M9** Наблюдаемость
Трейсы, метрики, алерты

- Что предъявлять после модуля

Каждый этап оставляет работающий результат.

Модуль	Что делаешь	Что показываешь
M0	Осваиваешь цикл на GET /ping	Отдельное ревью, тест и запись понимания
M1	Запускаешь и дополняешь готовый каркас	Приём, БД, доступ и безопасные повторы
M2	Подключаешь один реальный LLM-провайдер	API → извлечение → БД; учтён каждый вызов
M3	Добавляешь историю и уточнения	Новая реплика продолжает прежнее обращение
M4	Сравниваешь соседей и LLM-классификацию	Тип, приоритет и разбор ошибок на данных

M4 не требует обучения модели с нуля, кластеризации или регрессии.

- Что предъявлять после модуля

Соединить компоненты и проверить их вместе.

Модуль	Что делаешь	Что показываешь
M5	Ищешь доступные источники, проверяешь факты	Ответ с основанием или объяснимый отказ
M6	Собираешь один граф и локальный MCP-инструмент	Путь до действия, пауза и работа оператора
M7	Проверяешь качество и границы доступа	Реальные предсказания, атаки и регрессии
M8	Добавляешь Redis Streams и worker	Повторы без дублей, сбои, бюджет, нагрузка
M9	Связываешь trace, логи и метрики	Видно, где обращение задержалось и почему

Сквозной путь растёт с M2. В M8 очередь заменяет явный запуск обработки. В M6 достаточно одного графа; мультиагентная система не требуется.

Сначала определить тип. Затем выполнять нужные проверки.



Неподтверждённый тип или приоритет после LLM → оператор. Защитные правила проверяются перед действием. Номера S1-S10 обозначают зоны ответственности, а не порядок исполнения.

Не хватает адреса? Уточнить и продолжить.

Учебная иллюстрация: услуга активна, контакт получен от канала, известных блокирующих условий нет.

4. Эффект подтверждён

«Заявка создана. Пожелание “завтра” сохранено».

Конкретный слот не обещаем, пока он не назначен. Для этого действия нужны отдельные условия.

Создание заявки	Подтверждено инструментом
Статус обращения	done
Повтор того же действия	Прежний результат

Одно действие → один подтверждённый эффект.

- Навигация по материалам

Открывай файлы в порядке работы.

README.md модуля	Результат, зависимости и маршрут.
zadanie.md	Текущий пункт: что сделать и какие границы.
details/	Объяснения и примеры к пункту.
kriterii-priyomki.md	Каким сценарием доказать готовность.
detalnoe-review.md	Что проверить отдельным ревью.

Если документы расходятся

Общие правила сервиса задаёт [course/contracts.md](#).

[ai_context/](#) помогает ориентироваться. Формат данных описывает [data/SCHEMA.md](#).

Критерии приёмки полезно прочитать до написания кода: тогда результат задачи понятен заранее.

- Первый запуск

Начни с процесса.

Затем подними готовый каркас.

- 1 M0: подготовь рабочие записи.**
Шаблоны соглашения, решений, прогресса и промптов лежат в [docs/_templates/](#).
- 2 Пройди цикл на /ping.**
Небольшая задача проверит сам способ работы.
- 3 M1: разбери конфигурацию.**
Python 3.12, uv и Docker; требования – в M1.1 и M1.10.
- 4 Подними и проверь каркас.**
Найди расхождения с заданием и закрой их.

```
# После подготовки M1.1  
make lock  
make up
```

```
# Проверки M1  
make lint  
make typecheck  
make test
```

Для тестов нужна отдельная доступная БД. Подробные условия запуска – в [README M1](#).

Локальный запуск читает `.env`, compose – свои настройки. Пустая строка не включает значение по умолчанию.

Один пункт – один полный цикл.

Двигайся небольшими шагами и закрывай каждый проверяемым результатом.

1. Прочитать

Задание, объяснение и критерии.

2. Сформулировать

Промпт-контракт на текущий пункт.

3. Реализовать

Получить код и понять изменения.

4. Провести ревью

Отдельная сессия ИИ в роли критика.

5. Проверить

Прогнать сценарии приёмки.

6. Объяснить

Своими словами записать решение.

7. Зафиксировать

Отметить закрытый пункт в прогрессе.

Если есть ошибка

Исправить → повторить нужные проверки.

ИИ помогает реализовать и найти несоответствия. Принимаешь результат ты или куратор.

- Промпт-контракт

Передай ИИ точный объём работы.

Реализуй только пункт $M\{n\}.\{x\}$.

Цель: <дословно из задания>

Что сделать: <дословно>

Контракты: <дословно>

Краевые случаи: <дословно>

Неизменяемые ограничения:

<схемы и сигнатуры закрытых пунктов>

Не выходи за пределы текущего пункта.

Не меняй зафиксированные контракты.

Если нужно изменение — опиши его для отдельного решения.

Что приложить

Файлы текущего пункта, нужный код, критерии проверки и действующие ограничения.


Что попросить на ревью

Найти нарушение конкретного требования, показать сценарий ошибки и способ проверки.

Если ИИ предлагает «заодно» будущий модуль, вынеси это в отдельное решение. Объём текущего пункта остаётся управляемым.

- Учебные данные

Вход – модели. Эталон – проверяющему.



Бери course-pack-1

`load_course_inputs` возвращает входы без gold. Полные эталоны доступны проверяющему через `load_course_cases`.

Сохраняй честность проверки

Не передавай модели expected, case_id и служебные теги. Спорный эталон фиксируй с основанием; не подгоняй его под ответ модели.

Пакет синтетический; независимое человеческое ревью ещё pending. Наличие эталонов не доказывает качество приложения. Regression известен при разработке и не заменяет test.

У каждого параметра должны быть смысл и проверка.

Группа	Что фиксировать	Как оценить выбор
Вызов LLM	Модель, промпт, temperature, лимит ответа	Точность полей, вариативность, цена
Контекст	Бюджет истории, правила отбора, лимит уточнений	Сохранены ли исправления; нет ли лишних вопросов
Поиск	Размер фрагментов, top-k, гибрид, реранкинг	Найдено ли доказательство; стоимость поиска
Надёжность	Таймауты, повторы, fallback, TTL кеша	Сбой завершился предсказуемо; эффект не повторился
Бюджет	Лимиты токенов и стоимости на обращение	Учтён каждый вызов; лимит останавливает расходы

M2: temperature ≈ 0 для извлечения. Одинаковые ответы не гарантированы.

Разделяй обязательное правило и результат эксперимента.

Фиксировано контрактом

> 15 000 ₽

Подтверждённая сумма выше порога → оператор.

15 000 само по себе не вызывает эскалацию; 15 001 – вызывает. Остальные применимые правила проверяются независимо.

Не выдумывай сумму и не читай её из эталонной разметки в рантайме.

Подбирается на dev

- 1 Попроси 2-3 варианта и их компромиссы.
- 2 Сравни на одном наборе и одной метрике.
- 3 Запиши выбор, альтернативы и причину.
- 4 Зафиксируй настройки до итогового test.

Например: top-k, порог соседей, число уточнений. Не каждый параметр задания свободен для изменения.

Тип, срочность и маршрут отвечают на разные вопросы.

Поле	Вопрос	Пример
req_type	Что это за обращение?	заявка
priority	Насколько срочно?	срочный
validation_outcome	Что показали проверки?	need_info
route_decision	Что делать дальше?	уточнение
status	В каком состоянии обращение?	need_info

Срочность управляет порядком в очереди оператора. Она сама по себе не определяет маршрут обработки.

- На чём делать упор · M5

Ответ должен опираться на доступный источник.

Ограничить доступ

Сервер задаёт, какие документы можно читать.



Найти основание

Поиск учитывает права и актуальность источника.



Проверить ответ

Утверждение подтверждается найденным фрагментом.

Три исхода проверки

Подтверждено «да».

Подтверждено «нет».

Неизвестно.


Когда нельзя продолжать автоматически

Источник недоступен, права не позволяют его читать или нужного доказательства нет. Модель не заменяет отсутствующее основание догадкой.

SQL проверяет справочники, RAG – текстовые регламенты. Кеш, ответ и trace тоже соблюдают доступ.

- На чём делать упор · M6 и M8

Действие считается выполненным, когда эффект подтверждён.



Повтор доставки

То же событие не запускает второй побочный эффект. Сбой после создания ticket не должен создать ещё один ticket.

Оператор и пауза

Сохраняем состояние и причину передачи. Новая реплика – новое событие, даже если request_id остался прежним.

Проверь отдельно: повтор сообщения, повтор выполнения и повтор самого действия.

- На чём делать упор · M7-M9

Показывай ошибки рядом с итоговой метрикой.

Качество предсказаний

Сколько случаев прошло: `n/N`.

Где модель ошиблась.

Какие случаи не были исполнены.

Стоимость и время

Расход на обращение, повторы LLM, задержка и причина остановки.

Мок проверяет код. Live-прогон проверяет модель. Запись в БД подтверждает эффект.

Инварианты сервиса

- ✓ Отсутствующий адрес не придуман.
- ✓ Чужой документ не попал в ответ.
- ✓ Повтор не создал вторую заявку.
- ✓ Атака не вызвала запрещённое действие.

Нарушение инварианта нельзя скрыть высокой средней оценкой. После изменения промпта повторяй важные сценарии.

- Когда возникла проблема

Возвращайся к точному требованию и наблюдаемому сбою.

Код расходится с заданием

Пункт: $M\{n\}.\{x\}$

Требование: <цитата>

Фактическое поведение: <что случилось>

Вход для воспроизведения: <пример>

Ожидаемый результат: <по контракту>

Исправь это расхождение.

Сохрани остальные контракты.

После исправления – отдельное ревью и относящиеся к изменению проверки.

Несколько попыток не помогли

Запиши ограничение, причину и условие возврата в [docs/decisions.md](#).

Для некритичного пункта можно продолжить по правилам M0.7.

Если следующие модули зависят от результата, сначала устрани блокировку. Например, неработающий запуск каркаса нельзя просто отложить.

- Приёмка

Три уровня готовности.

На каждом нужны доказательства.

Пункт	Модуль	Курс
Отдельное ревью.	Рабочий путь.	Сквозные сценарии.
Сценарии проверки.	Значимый сбой.	Результаты оценки.
Объяснение своими словами.	Интеграционная приёмка.	Эффекты, trace и расходы.

Минимальный комплект: команда запуска, вывод сценариев или отчёт, версии конфигурации и промптов, известные ограничения.

В [docs/decisions.md](#) – что выбрано, какие альтернативы были и почему. В [docs/progress.md](#) – что закрыто. В [prompts/](#) – версии промптов.

- Можно начинать

Возьми один пункт. Доведи его до доказательства.

1 Открой [M0: старт](#) и подготовь рабочее соглашение.

2 Пройди полный цикл на [GET /ping](#).

3 Переходи к [M1: запуск и проверка каркаса](#).

После каждого шага ответь: «Что теперь работает? Чем я это проверил? Как я объясню решение?»